

Relatório do trabalho de Inteligência artificial

Implementação dos algoritmos classificadores de redes neurais: Perceptron, Adaline e MLP.

Carlos Alberto Moraes Moura Filho

0223164-6

Universidade de Fortaleza

Ciências da computação

Fortaleza – CE, Brasil

RESUMO – As redes neurais artificiais possibilitam solucionar problemas de classificação e reconhecimento de padrões implementando modelos computacionais que se inspiram no funcionamento do cérebro humano, criando camadas de neurônios interconectados.

I. INTRODUÇÃO

O presente relatório tem por objetivo descrever o trabalho desenvolvido para solucionar os problemas propostos por meios dos algoritmos de classificadores das redes neurais artificiais estudados na terceira etapa da cadeira de Inteligência artificial, no curso de Ciências da computação da Universidade de Fortaleza, em 2024.1.

II. METODOLOGIA

ALGORITMOS

Os algoritmos propostos para implementação desse trabalho foram: Perceptron simples, Adaptive Linear Neuron – ADALINE e o MultiLayer Perceptron – MLP.

Todos os algoritmos deveriam ser rodados 100 vezes com as mesmas entradas de dados, para que fossem gerados os dados para comparação.

Na primeira etapa foram processados dois conjuntos de dados, o primeiro conjunto de dados, spiral.csv, representavam dados rotulados em duas classes distintas, caracterizando assim, uma classificação, já o segundo, aerogerador.dat, era um processamento para prever a potência

gerado por um aerogerador com base na velocidade do vento, caracterizando um problema da natureza de regressão.

Já na segunda etapa os dados foram extraídos de uma base de dados online (<https://archive.ics.uci.edu/dataset/186/wine+quality>), conjunto esse que foi utilizado para avaliar a qualidade de vinhos.

III. RESULTADOS

Carregamos os dados propostos no modelo e após a execução das 100 rodadas obtivemos os seguintes dados:

PERCEPTRON SIMPLES

O classificador foi executado com os seguintes hiperparâmetros de inicialização:

$\eta = 0.5$ (taxa de aprendizado)

épocas = 100

→ 1º conjunto de dados

Algoritmo classificador: Perceptron

Fonte de dados: **espiral**

Taxa de aprendizado: 0.5

Total de épocas: 100

Resultados:

	media	mediana	minimo	maximo	d.padrao
acuracia	0.6339	0.6500	0.3100	0.7475	0.0806
especificidade	0.6340	0.6519	0.3420	0.7940	0.0848
sensibilidade	0.6340	0.6496	0.2802	0.7668	0.0897

Tempo de execução: 3 minutos e 46.063 segundos

Resultado encontrado na 100ª época

Algoritmo classificador: Perceptron

Fonte de dados: **aerogerador**

Taxa de aprendizado: 0.5

Total de épocas: 100

Resultados:

	media	mediana	minimo	maximo	d.padrao
eqm	110.8538	111.0980	101.7226	119.2763	3.0373

Tempo de execução: 5 minutos e 32.980 segundos

Resultado encontrado na 100ª época

Apresentamos os gráficos de convergência e do desempenho:

espiral




Figura 1 – Convergência




Figura 2 – Desempenho

aerogerador




Figura 3 – Convergência




Figura 4 – Desempenho

→ 2º conjunto de dados

F Algoritmo classificador: Perceptron
Fonte de dados: **red_wine**
Taxa de aprendizado: 0.5
Total de épocas: 100

Resultados:
media mediana minimo maximo d.padrao
eqm 0.0346 0.0346 0.0332 0.0363 0.0006

Tempo de execução: 3 minutos e 11.061 segundos
Resultado encontrado na 100ª época

Algoritmo classificador: Perceptron
Fonte de dados: **white_wine**
Taxa de aprendizado: 0.5
Total de épocas: 100

Resultados:
media mediana minimo maximo d.padrao
eqm 0.0125 0.0125 0.0122 0.0130 0.0001

Tempo de execução: 9 minutos e 2.373 segundos
Resultado encontrado na 100ª época

E, também, apresentamos os gráficos gerados para as amostras desse outro conjunto de dados:

red_wine




Figura 5 – Convergência




Figura 6 – Desempenho

white_wine




Figura 7 – Convergência




Figura 8 – Desempenho

De posse dos dados de resultado de cada conjunto de dados, são salvos os arquivos de imagens, do gráfico de convergência e do gráfico de desempenho, em arquivos '.png', os resultados em um arquivo '.txt' e toda a coleta de dados das rodadas em um arquivo '.csv'.

ADAPTATIVE LINEAR NEURON

Nesse classificador foi setado os seguintes hiperparâmetros de inicialização:

$\eta = 0.0001$ (taxa de aprendizado)

épocas = 100

$e = 0.0000000001$ (precisão)

Da mesma forma do perceptron, apresentamos os resultados e os gráficos de convergência e de desempenho para os dois conjuntos de dados:

→ 1º Conjunto de dados

Algoritmo classificador: Adaline
Fonte de dados: **espiral**
Taxa de aprendizado: 0.0001
Total de épocas: 10
Precisão: 1e-10

Resultados:

	media	mediana	minimo	maximo	d.padrao
acuracia	0.4939	0.4525	0.3600	0.6325	0.0825
especificidade	0.4962	0.4726	0.3526	0.6536	0.0811
sensibilidade	0.4921	0.4625	0.3411	0.6749	0.0910

Tempo de execução: 0.767 segundos
Resultado encontrado na 10ª época

Algoritmo classificador: Adaline
Fonte de dados: **aerogerador**
Taxa de aprendizado: 0.0001
Total de épocas: 10
Precisão: 1e-10

Resultados:

	media	mediana	minimo	maximo	d.padrao
eqm	111.5201	111.4522	105.1523	121.7230	2.9074

Tempo de execução: 0.245 segundos
Resultado encontrado na 10ª época

espiral




Figura 9 – Convergência




Figura 10 – Desempenho

white_wine




Figura 15 – Convergência




Figura 16 – Desempenho

aerogerador




Figura 11 – Convergência




Figura 12 – Desempenho

→ 2º Conjunto de dados

Algoritmo classificador: Adaline
Fonte de dados: **red_wine**
Taxa de aprendizado: 0.0001
Total de épocas: 10
Precisão: 1e-10

Resultados:
media mediana minimo maximo d.padrao
eqm 0.0536 0.0686 0.0335 0.0724 0.0176

Tempo de execução: 0.503 segundos
Resultado encontrado na 10ª época

Algoritmo classificador: Adaline
Fonte de dados: **white_wine**
Taxa de aprendizado: 0.0001
Total de épocas: 10
Precisão: 1e-10

Resultados:
media mediana minimo maximo d.padrao
eqm 0.0190 0.0243 0.0122 0.0249 0.0060

Tempo de execução: 0.817 segundos
Resultado encontrado na 10ª época

red_wine




Figura 13 – Convergência




Figura 14 – Desempenho

E, ao final, temos os mesmos arquivos gerados: um '.png' para cada um dos dois gráficos apresentados, '.txt' para os resultados e '.csv' com os dados da rodada.

MULTILAYER PERCEPTRON

Só tenho um esboço inicial da implementação do modelo, mas que não consegui finalizar para apresentar no tempo hábil do projeto.

IV. CONCLUSÕES

O custo computacional para a convergência dos resultados no modelo do perceptron simples é o maior comparado com os outros modelo, porque ele não consegue convergir totalmente para o ótimo do problema e passa por todas as 100 épocas em todas as 100 rodadas.

Já no modelo Adaline temos acontece a convergência antecipada pois o modelo consegue interromper a execução quando encontra uma solução aceitável para o problema.

Não foi possível avaliar a solução do modelo MLP, visto que não conclui a implementação dele.

REFERÊNCIAS

da Silva, Ivan N.; Spatti, Danilo H.; Flauzino, Rogério A.; **Redese Neurais Artificiais para Engenharia e Ciências Aplicadas**. Editora Artliber, 2.ed. – 2016

Souza Barbosa, Paulo Cirillo; **Sistemas Inteligentes - RNA** – UNIFOR, 2024.1

Raschka, Sebastian; **What is the difference between a Perceptron, Adaline, and neural network model?** Disponível em: <<https://sebastianraschka.com/faq/docs/diff->

perceptron-adaline-neuralnet.html>.
Acessado em: 05/06/2024

Rocha, Júlio C. P.; **Introdução ao Perceptron multicamadas passo a passo**. Disponível em:
<<https://juliocprocha.wordpress.com/2020/03/30/introducao-ao-perceptron-multicamadas-passo-a-passo/>>. Acessado em: 14/06/2024